

Fernerkundliche Zeitreihenanalyse von Borkenkäferbefällen im Forst am Beispiel des Harz

Nikolaos Kolaxidis

M.Sc. Geographie

pd281@uni-heidelberg.de

Keywords

Forest monitoring, stress monitoring, bark beetle, remote sensing, multispectral satellite imagery, vegetation indices, NDVI, multi-temporal analysis

EINFÜHRUNG

Laut Bericht des IPCC [2015], dem renommiertesten Klimabericht der heutigen Zeit, befindet sich das Klima der Erde in einem Wandel, welcher unbestreitbar durch anthropogene Aktivitäten beeinflusst, „extrem wahrscheinlich“ [IPCC 2015] sogar hervorgerufen wurde. Als Folgen des Klimawandels werden beispielsweise Biodiversitätsverlust, humanitäre Katastrophen und die Steigerung von Extremwetterereignissen angeführt, die durch anthropogene Aktivitäten wie zum Beispiel der Emission von Treibhausgasen und der Rodung von Waldflächen neben vielen anderen weiter verschlimmert werden [IPCC 2015]. Wälder werden gerade in der Debatte um den Klimawandel oft als wichtiger Teil des globalen Ökosystems gesehen und deren besondere Gefährdung sowohl durch klimatische Veränderungen wie auch durch anthropogene Aktivitäten aufgezeigt [Seidl et al. 2017]. Ein weiterer oft in solchen Debatten unbeleuchteter Faktor, der zu den natürlichen Entwicklungsprozessen von Wäldern in gemäßigten Breiten gehören, sind Schädlinge. Durch den fortschreitenden Klimawandel wird die Ausbreitung und Häufigkeit von Forstsäädlingen, die sowohl pflanzlicher wie auch tierischer Herkunft sein können, begünstigt, wodurch sie zu einem zunehmenden Problem werden [Seidl et al. 2017, Kautz et al. 2017, Minarik et al. 2021]. Das Monitoring von Befällen wird dadurch immer wichtiger, um epidemische Ausbrüche zu mitigen oder einzudämmen. Es stellt sich die Frage, wie übliche manuelle Methoden durch automatisierte technische Methoden unterstützt werden können. Dies wird im Folgenden anhand eines Fallbeispiels analysiert.

FORSTSCHÄDLINGE

Auch hier in Deutschland, wo Wälder 2017 eine Fläche von ca. 11,45 Millionen Hektar ausmachen, was ca. 30 % der Landesfläche entspricht [Bundeswaldinventur 2017, Statista 2023], ist ein Zunehmen des Schädlingsbefalls im Forst zu beobachten. In *Abbildung 1* ist der Verlauf der bundesweiten Absterberate von Waldbäumen zu sehen. Hier wird deutlich, dass ab 2018 eine massive Zunahme vor allem an geschädigten Nadelbäumen zu verzeichnen war. Zwar sind in diesen Jahren laut DWD [2023] die Temperaturen auch weiter gestiegen, was aufgrund der langphasigen Trockenheit weiterhin eine große Problematik für den Walderhalt darstellt, aber wie die Ausscheiderate in *Abbildung 2* zeigt, nahmen die Anteile an schädlingsverursachten Schäden von 2018 bis 2020 stark zu und bildeten im Gegensatz zu den letzten 20 Jahren einen ungewöhnlich großen Teil der Schadensherkunft [Bundeswaldinventur 2017]. Hier ist eine Wechselwirkung zwischen Trockenheit beziehungsweise höheren Temperaturen und der Vermehrung von Schädlingen zu vermuten, wie sie Marini et al. [2012] und Beudert et al. [2015] bereits bestätigen. Diverse auch aktuellere Quellen nach dem massiven Anstieg an Schadensfällen beschäftigen sich mit der Thematik, da die Problematik durch den weiteren zu erwartenden Temperaturanstieg wahrscheinlich weiterhin zunehmen wird [Seidl et al. 2017, Minarik et al. 2021].

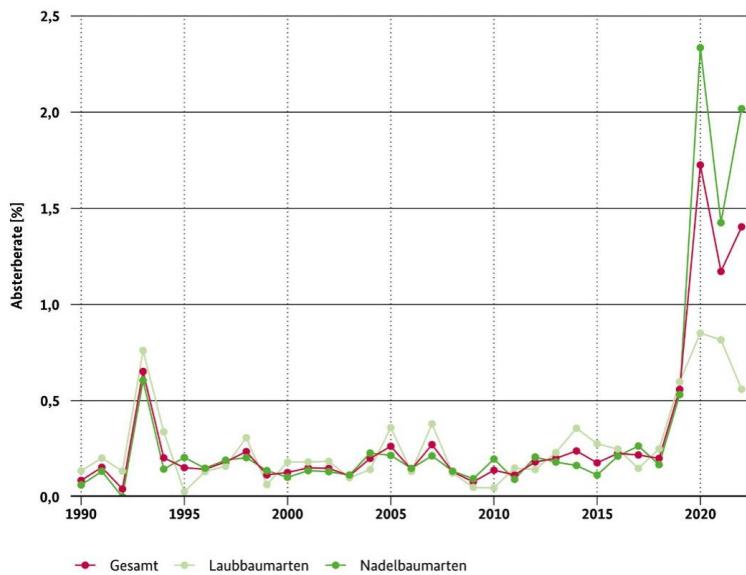


Abbildung 1. Bundesweite Absterberate von Waldbäumen [BMEL 2023]

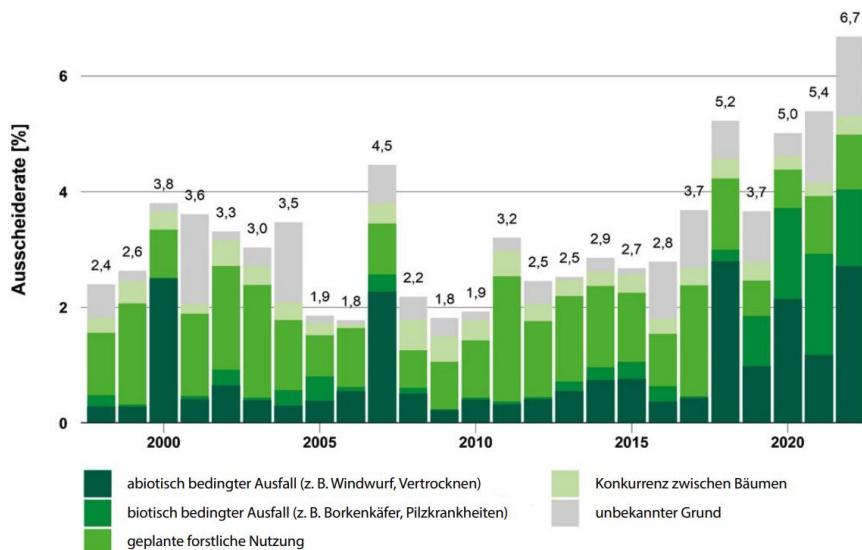


Abbildung 2. Bundesweite Ausscheiderate von Waldbäumen [BMEL 2023]

Borkenkäfer

Der bedeutendste biotische Schädling, der hier in Deutschland festzustellen ist, ist der Borkenkäfer, mit lateinischem Namen *Ips spp.* (L.) [Spektrum Akademischer Verlag 1999, Barta et al. 2021]. Insgesamt sind sechs Borkenkäferarten bekannt, die in Zentraleuropa vorkommen, wovon drei, namentlich *Ips typographus*, *Ips duplicatus* und *Ips amatinus*, eine ernsthafte Bedrohung vor allem für mitteleuropäische Sekundärwälder darstellen [Barta et al. 2021, Overbeck/Schmidt 2011]. Borkenkäfer sind eigentlich ein wesentlicher Bestandteil eines jeden Waldökosystems, da sie insbesondere geschwächte Bäume befallen und so eine Art natürlichen Zersetzung- und Regulierungsmechanismus darstellen. Doch während längerer Trockenperioden oder anderen Stresssituationen wie starken Windereignissen und folglich hohen Mengen Sturmholz können sie sich epidemisch vermehren („Ausbruch“ [Barta et al. 2021]) und auch gesündere Bäume befallen, sodass ein genereller massiver Anstieg in sterbenden Bäumen zu verzeichnen ist [Overbeck/Schmidt 2011, Seidl et al. 2017, Barta et al. 2021].

Ein typischer Befallsverlauf gestaltet sich für die Bäume meist in bekannter Reihenfolge: erst werden Löcher in der Rinde und Holzstaub auf dem Boden unter dem Baum sichtbar, dann folgen nach einigen Monaten Stresssymptome ähnlich wie bei Trockenbedingungen, also Farbveränderungen der Blätter beziehungsweise Nadeln, Entlaubung und Rindenfäule bis hin zum irreversiblen Tod der Bäume, da die Verbindung von Wurzeln

und Blättern gekappt wird. Einzelne Bäume können in den frühen Stadien visuell unterschiedlich auf den Befall reagieren, sodass die Früherkennung durch rein visuelle Maßnahmen oft ineffizient ist [Barta et al. 2021, Marvasti-Zadeh et al. 2022]. Das Borkenkäfermonitoring wird üblicherweise durch Förster im Rahmen von Feldbegehungen durchgeführt. Allerdings ist durch das bereits hohe und anzunehmende weiter steigende Ausbruchsniveau nicht möglich, große Gebiete in ausreichender Zeit zu überwachen. Hier hat der Einsatz von fernerkundlichen Daten großes Potenzial, wie Senf et al. [2017] und Marvasti-Zadeh et al. [2022] beschreiben.

Fragestellung

Die Fernerkundung kann ein wirksames Instrument für die rechtzeitige, großflächige und automatisierte Überwachung von Borkenkäferausbrüchen sein [Marvasti-Zadeh et al. 2022]. Wie Senf et al. [2017] beschreiben, steigen die Publikationszahlen zum Thema Schädlingsbefallsmonitoring mit fernerkundlichen Daten ab 2013 rapide an, was auf die Dringlichkeit der Forschung zu diesem Thema hindeutet. Gerade Borkenkäfer werden seit 2013 neben blätterfressenden Schädlingen wesentlich öfter in Publikationen genannt. Da Nadelbäume ganzjährig Nadeln tragen und bereits kleine Änderungen in ihren Reflektionswerten durch leichte Trockenheitserscheinungen erkannt werden können, eignen sie sich besonders für eine Befallsanalyse.

Eine oft genutzte fernerkundliche Methodik zur Quantifizierung von Schädlingsbefällen und Schadensvisualisierungen sind Zeitreihenanalysen, wie sie zum Beispiel bei Stych et al. [2019] und Fernandez-Carrillo et al. [2020] genutzt wurden. Dabei wird ein Datensatz evaluiert, der Daten mit verschiedenen Zeitpunkten eines Gebietes beinhaltet (multi-temporal), sodass Verläufe und Prozesse sichtbar werden. Die sich ergebende Fragestellung ist, inwieweit eine multi-temporale Befallsanalyse mit fernerkundlichen Daten als R-Script umgesetzt und automatisiert werden kann und wie sich der Befall beziehungsweise das Waldwachstum von 2018 bis 2020 anhand eines Beispiels entwickelt hat. Ein besonderer Fokus liegt dabei auf dem Erfassen von Entwicklungstrends von geschädigten Bäumen und der Nachvollziehung der Ausbreitung der Borkenkäfer, falls ein Befall festgestellt werden kann.. Als Beispiel soll der Harz dienen, da er einen großen Anteil an Nadelbäumen hat und bereits langjährig bestehende und durch die Umstände entsprechend weitere Borkenkäferbefälle in dem genannten Zeitraum nachgewiesen wurden [Nationalpark Harz 2021, Sternal 2020]. Die Methodik der Analyse dazu wird nach einigen theoretischen fernerkundlichen Grundlagen erläutert.

SPEKTRALREFLEKTIONEN UND VEGETATIONSINDIZES

Fernerkundliche Daten wie zum Beispiel Satellitendaten werden in großem Maße zur Erkennung und zum Monitoring von Stress in Vegetationen genutzt, da sie multispektrale Aufnahmen liefern können, aus denen Indizes berechnet werden können, die Aussagen über Vitalität, Biomasse sowie Chlorophyll- und Wassergehalt von Pflanzen ermöglichen. Multispektralität kann durch folgende *Abbildung 3* erklärt werden, hier wird gezeigt, dass alle Objekte verschiedene Wellenlängen des Lichts absorbieren und reflektieren [Hadoux 2014]. Sie zeigt dabei die ideal-typischen Spektralreflexionen verschiedener Objekte auf dem Boden in den Bereichen des sichtbaren Lichts und längeren Wellenlängen. Es ist klar zu sehen, dass die längeren für uns Menschen unsichtbaren Wellenlängen viel mehr spektrale Informationen liefern als das sichtbare Licht. Diese Informationen zu messen und nutzbar zu machen ist die Aufgabe von multispektralen Messinstrumenten. Die einzelnen Kurven der Spektralreflexionen geben Hinweise darauf, um was für Objekte es sich in den Bildern handelt und dies kann in Klassifikationsalgorithmen zur automatisierten Evaluierung eines jeden Objektes in Satellitenbildern genutzt werden [Jensen 2007].

Gerade Vegetationen haben im Vergleich zu anderen Bodenobjekten einen sehr charakteristischen Kurvenverlauf in ihrer Spektralreflexion, wie in *Abbildung 3* zu sehen ist. Sie absorbieren einen hohen Anteil des Lichts im blauen und roten Wellenbereich um 490 und 665 Nanometer, reflektieren im Vergleich dazu Licht im grünen Wellenlängenbereich um 560 Nanometer und hohe Mengen Licht im Nahen Infrarotbereich (NIR) um 835 Nanometer, welcher nicht mehr für das menschliche Auge sichtbar ist [X ESA 2023a, X Gross 2005]. Dies ist in den Verläufen der Spektralreflexionen einzigartig und unterscheidet Vegetation stark von Böden, Gewässern und Gebäuden [X Jensen 2007]. Das liegt an Pigmenten in Blättern, die während des Photosyntheseprozesses mit dem Sonnenlicht reagieren. Chloroplasten in den Blättern, zellähnliche Strukturen, die einen hohen Anteil an Chlorophyll enthalten, absorbieren dabei das Licht des blauen und roten Bereiches und reflektieren einen Teil des Lichts im grünen Bereich (wie in *Abbildung 3* zu sehen). Aus diesem Grund werden die Blätter als grün wahrgenommen, da sie hauptsächlich die grünen Wellenlängen zurück zu unseren Augen reflektieren [X Gross 2005].

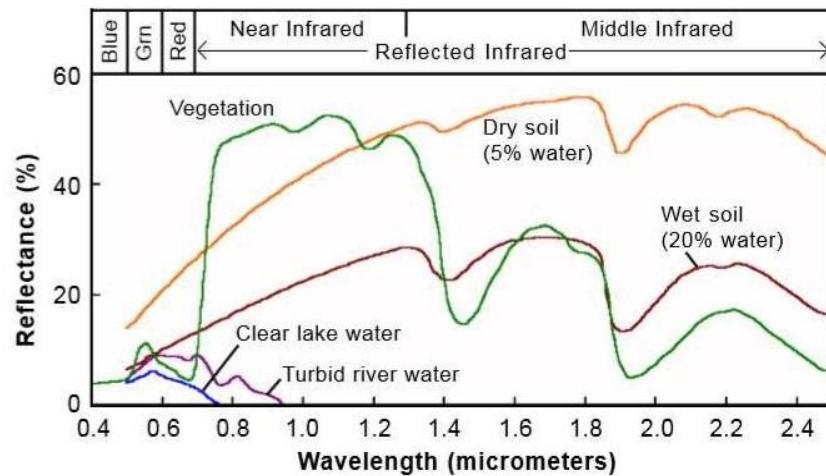


Abbildung 3. Spektralreflexionen von typischen Bodenobjekten (adaptiert nach Mondal [2018])

Das ändert sich mit dem Alter und dem Zustand von Vegetationen im Bezug auf Wasserverfügbarkeit und Nährstoffverfügbarkeit, wie in *Abbildung 4* zu sehen ist. Die Chlorophyllkonzentration nimmt ab und die Reflexion der ebenfalls in Vegetation vorhandenen Karotinoide im roten Bereich tritt stärker hervor, weshalb die Blätter röter und bräunlicher erscheinen [X LPIMIC 2022]. Darüber hinaus streuen und reflektieren die Zellwände innerhalb der Blätter große Mengen an Licht im NIR, da es mit Chlorophyll kaum interagiert. Deshalb sind die Reflexionswerte von gesunder grüner Vegetation im NIR so hoch und so bildet sich auch der so charakteristische Kurvenverlauf ihrer Spektralreflexion [X Gross 2005]. Aufgrund dessen kann die Chlorophyllkonzentration in den Blättern, mit anderen Worten deren Grünton, Auskunft über die Pflanzenvitalität anzeigen und auf Stress verschiedener Art und Herkunft hinweisen. Die Blattdichte und daher die absolute Biomasse kann diese Werte allerdings ebenfalls beeinflussen, sodass zu beachten ist, dass sich durch das typische jährliche Wachstum über das Jahr eine Saisonalität in den Werten einstellen kann und ein Vergleich nur unter Einbezug von weiteren Faktoren wie Aufnahmezeitpunkt und generelle klimatische Änderungen möglich ist [X Jensen 2007, X Lilienthal 2014]. All diese Merkmale der Spektralkurven können zur Berechnung von Indizes benutzt werden, die Aussagen zu bestimmten Faktoren des Pflanzenzustands erlauben.

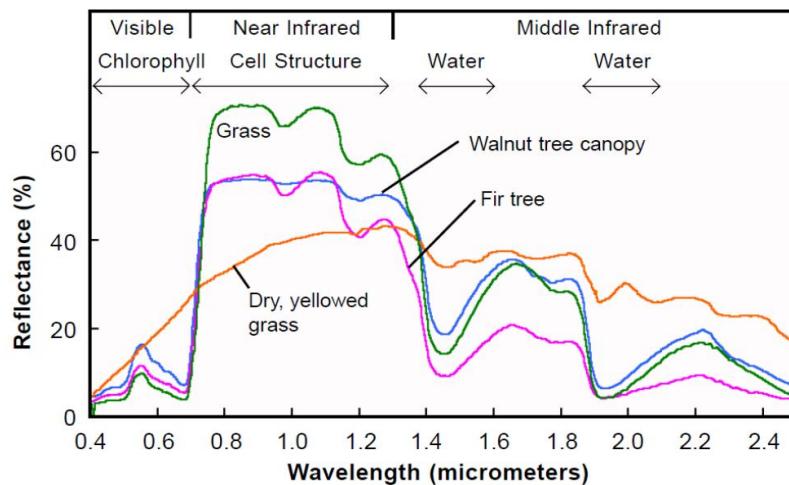


Abbildung 4. Spektralreflexionen von unterschiedlichen Vegetationen abhängig von ihrem Wassergehalt (adaptiert nach Hadoux [2014])

Der ausgeprägte Unterschied in den Reflexionen zwischen dem roten und dem NIR-Bereich, wie er in *Abbildung 3* zu sehen ist, ist zum Beispiel sehr nützlich bei der Klassifizierung und Unterscheidung von Vegetation zu anderen Objekten. Auf Basis dieses Umstandes wurde ein Index entwickelt, genannt Normalized Difference Vegetation Index (NDVI), der durch eine einfache Rechnung die Vegetationsvitalität bestimmen kann:

$$NDVI = \frac{NIR - Red}{NIR + Red}$$

(adaptiert nach Rouse et al. [1973])

Die Berechnung ergibt einen Wertebereich zwischen -1 und 1, der Auskunft darüber gibt, wie photosynthetisch aktiv die Vegetation ist. Daraus ist auf die Vitalität einer Pflanze zu schließen [Jensen 2007, Konecny 2014]. Niedrige Werte unter 0 weisen auf fehlende Vegetation, Werte von 0 bis 1 auf steigende photosynthetische Aktivität und daher Pflanzenvitalität und Biomasse hin. Andererseits ist auch das Aufzeigen von Stressfaktoren wie Wasser- und Nährstoffverfügbarkeit dadurch möglich [Aryal et al. 2022]. Im Bezug zur Fragestellung kann der Index vor allem zur Identifikation von Schäden im Wald genutzt werden, um zu eruieren, ob die Schäden großflächig oder vereinzelt auftreten. Dadurch sind gezieltere Aussagen zum Stresshergang und ein anschließendes Monitoring möglich. Außerdem können durch den Zeitfaktor, der durch die Multitemporalität einbezogen wird, die Entwicklung von möglichen Befällen nachvollzogen und Herde erkannt werden.

MATERIALIEN UND METHODEN

Untersuchungsgebiet

Untersucht werden soll der Harz, das größte Mittelgebirge Norddeutschlands mit über 90 Kilometer Länge und 30 Kilometer Breite, gelegen im Dreiländereck Niedersachsen, Sachsen-Anhalt und Thüringen in Deutschland. Geologisch gesehen ist der Harz eine paläozoische Gesteinsformation, die steil in Nordwest-Südost-Richtung geneigt ist und aus den umgebenden tertiären Schichten herausragt, die im Pleistozän durch periglaziale Umstände überprägt wurden. Die Hochflächen des Unterharzes im östlichen Teil liegen auf etwa 300 Metern über dem Meeresspiegel und steigen im Oberharz auf eine Höhe von 971 Meter an. Der Brocken bildet dabei die höchste Erhebung mit 1,142 Metern [Overbeck/Schmidt 2011, Watanabe et al. 2004]. Eine Übersichtskarte kann in *Anhang 1* eingesehen werden, hier wird die Höhengliederung visuell nachvollziehbar dargestellt.

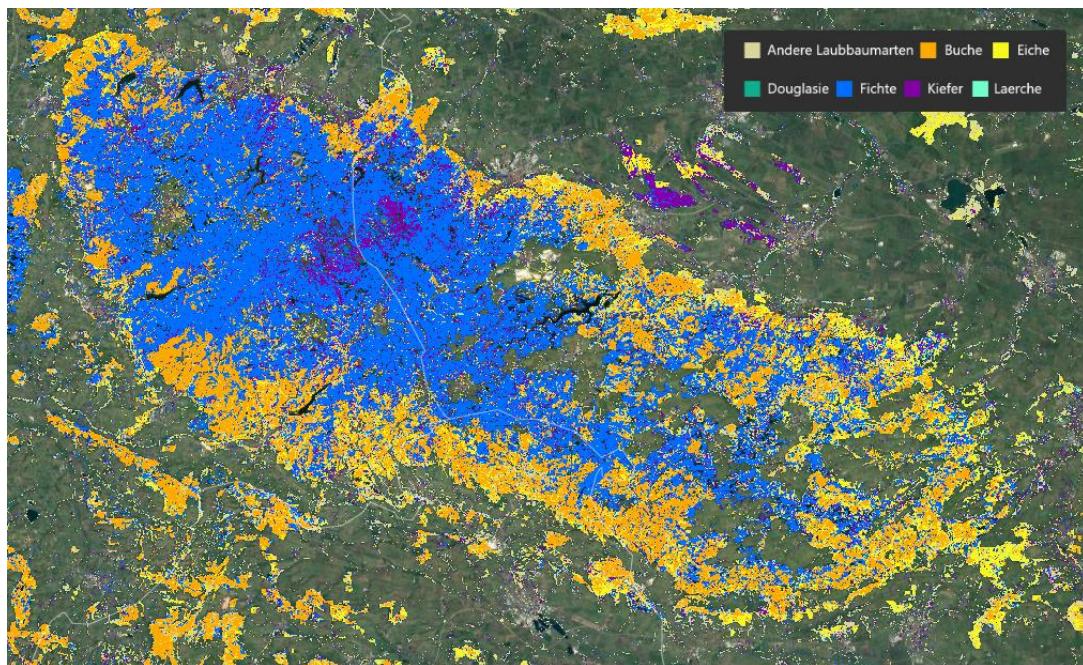


Abbildung 5. Baumbestand im Harz, Waldmonitor Deutschland (adaptiert nach Welle et al. [2022])

Zwei Testflächen (zu sehen in Abbildung 5 und näher in Abbildung 5), auch genannt “area of interest” (AOI), wurden willkürlich anhand ihres hohen Fichtenanteils ausgewählt, die durch die Analysen beispielhaft behandelt und anschließend verglichen werden sollen. Beide sind ca. 10,12 Quadratkilometer groß und liegen in der westlichen Hälfte des Harz. AOI 1 liegt ca. zwischen 51°85' bis 51°9' Nord und 10°45' bis 10°5' Ost im Westharz, AOI 2 ca. zwischen 51°8' bis 51°85' Nord und 10°65' bis 10°7' Ost im mittleren Harz, welches bereits zum Osthälfte gehört. Die Daten, die im Folgenden beschrieben werden, werden während der Vorprozessierung, die im Methodikteil erläutert wird, auf diese beiden Bereiche zugeschnitten, um Datenmengen zu verringern und die Vergleichbarkeit zu erhöhen. Werden nämlich zu viele Pixel in die Analyse mit einbezogen, können Neutralisierungseffekte eintreten und die Daten werden verfälscht.

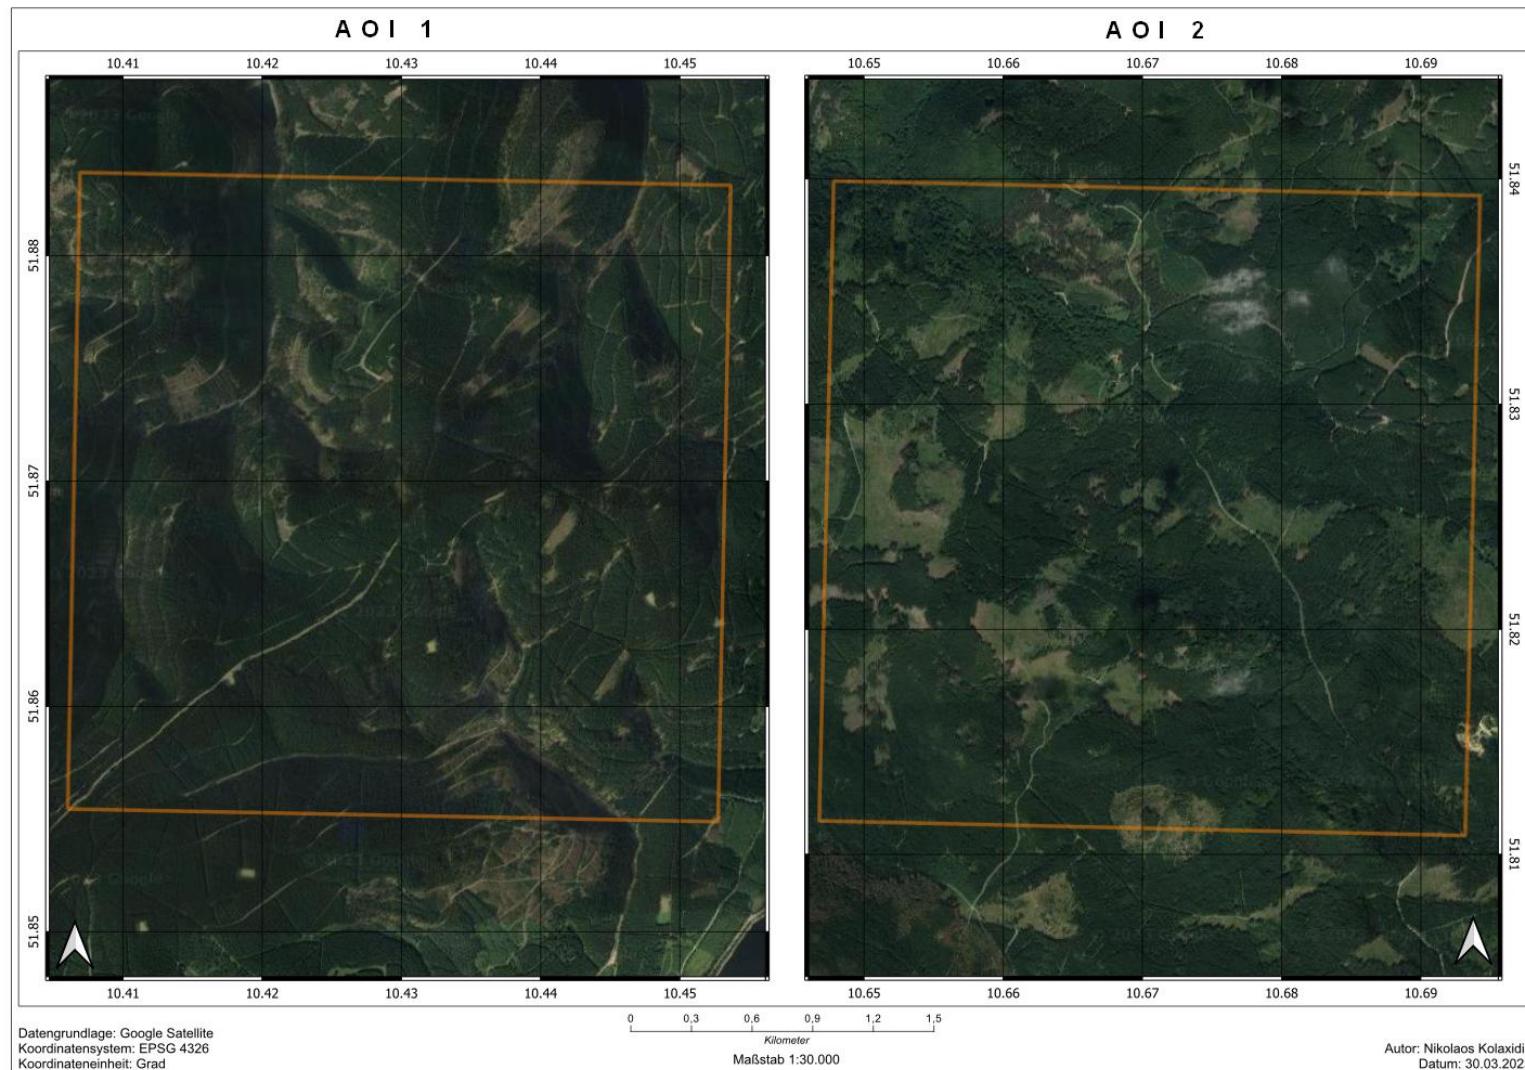


Abbildung 6. Übersicht über die beiden Testflächen [eigene Darstellung]

Daten

Es existieren viele Satellitenplattformen in der Erdumlaufbahn, die multispektrale Bilder für verschiedene Zwecke mit unterschiedlichen Auflösungen und Bandbreiten liefern. Deshalb ist es ratsam, im Vorfeld einen Datensatz auszuwählen, der den gewünschten Anforderungen entspricht. Die Daten sollten offen und frei zugänglich sein und dennoch eine hohe Auflösung in den benötigten Bändern bieten. Senf et al. [2017] beschreiben zudem, dass einer der wichtigsten Faktoren im Borkenkäfermonitoring eine hohe räumliche Auflösung zusätzlich zur Datenkontinuität darstellt. Wie in Aryal et al. [2022], Isioye et al. [2020] und Gomez et al. [2020] dargelegt, sind die von der ESA bereitgestellten Sentinel-2-Daten, die über den Copernicus Open Access Hub (<https://scihub.copernicus.eu/>) frei zugänglich sind, einer der daher bevorzugten Datensätze, da sie in den für die Fragestellung wichtigen Bändern eine höhere Auflösung von 10 Metern aufweisen als andere vergleichbare Datensätze wie Landsat 8/9 mit 30 Metern und MODIS mit 250 bis 500 Metern [ESA 2023a, NASA 2022a, NASA 2022b]. Mit einer Schwadbreite von 290 Kilometern und einer radiometrischen Auflösung von 12-Bit liefert das System auf dem Prozessierungslevel 1C geometrisch korrigierte Top-of-Atmosphere (TOA) Reflexionswerte mit einer hohen zeitlichen Auflösung von bis zu fünf Tagen, was durch zwei Satelliten mit ähnlichen Instrumenten (S2A und S2B) und versetzen Überflugzeiten erreicht wird. Das Sensorsystem ist in der Lage, Wellenlängen in 13 verschiedenen Bändern vom sichtbaren bis zum kurzweligen Infrarot zu erfassen, was vor allem auch das rote und das NIR-Band inkludiert, welche zur Berechnung des NDVI verwendet werden [ESA 2023a, Frampton et al. 2013].

Nach Registrierung und Einrichtung eines Kontos bei der ESA ist eine intuitive Auswahl von Daten für eine bestimmte AOI und einen bestimmten Zeitraum auf dem Copernicus Hub verfügbar. Hier kommen Aufnahmen der Tiles T32UNC und T32UPC in Frage, da der Harz zwischen diesen beiden Tiles liegt. Da die Datenmengen proportional zu der Anzahl an Aufnahmen zunehmen und gigantisch werden können, werden die Satellitenbilder meist nach einem bestimmten Zeitraum in das Long-Term-Archive (LTA) verschoben und müssen bei Wunsch erst geordert werden. Dies dauert zwar nicht lang, aber aufgrund fehlender Batch-Funktionen gestaltet es sich langwierig, viele Daten über einen großen Zeitraum herunterzuladen. Zusätzlich dazu gibt es für Privatuser Limitierungen bei der gleichzeitigen Order und beim Herunterladen der Daten, weswegen das manuelle Herunterladen von langen Zeitreihen zwar nicht empfohlen wird, das automatische Herunterladen mittels Packages aber auch limitiert ist. Das ist ein Grund dafür, dass in diesem Projekt ein möglichst knapper Zeitraum um das bekannte Ereignis gewählt wurde, wie in *Tabelle 1* zu sehen ist.

Das größte Problem bei optischen Satellitendaten ist die Wolkenbedeckung, da Wolken die verfügbaren Multispektraldaten einschränken oder die resultierenden Werte stark beeinflussen [Aryal et al. 2022]. Deshalb wird empfohlen, die Wolkenbedeckung der Bilder mit einem Parameter zu begrenzen und jedes Rasterbild genau zu prüfen, um sicherzustellen, dass die AOI wolkenfrei ist, bevor die Daten heruntergeladen werden. Das automatische Herunterladen solcher Rasterbilder kann selbst bei den Einstellungen zur Wolkenbedeckung zu unkontrollierbaren Wertfehlern führen, weshalb in diesem Projekt ähnlich wie bei Barta et al. [2021] kein automatisches Herunterladen von Rasterdaten verfolgt wurde. Möglich wäre dies innerhalb von R mit dem R-Package *sen2r* (<https://sen2r.ranghetti.info>), welches sowohl eine GUI wie auch Methoden zum Herunterladen und Prozessieren der Daten bietet. Eine anschließende Klassifizierung von Wolkenbereichen und deren gewählter und begrenzter Einbezug ist durch Nutzen einer Maske möglich, allerdings ist dies vor allem bei Langzeitreihen mit vielen Datensätzen nötig. Bei der kurzen Zeitreihe, wie sie hier behandelt wird, können die Daten noch händisch gesichtet werden. Darüber hinaus werden den Sentinel-2 Daten erst seit 2022 Masken beigelegt, sodass für die Zeiträume davor Maskendaten fehlen [ESA 2022b].

Um den Zeitraum des beobachteten Befalles möglichst voll zu umfassen, dabei die Datenmengen aber recht klein zu halten, da es sich um mehrmonatige Prozesse handelt [Senf et al. 2017], wurden Rasterdaten aus den Jahren 2018-2020 verwendet. Außerdem wurden mehrere Aufnahmen pro Jahr, insbesondere zwischen April und September, ausgewählt, um auch saisonale Unterschiede erfassen und bestimmen zu können. Um möglichst wolkenfreie Daten zu erhalten, wurde der genaue Zeitrahmen für die Aufnahmen eines einzelnen Jahres zwar weit gefasst, aber wenn möglich auf ähnliche Zeiträume eingegrenzt. Die resultierende Datengrundlage mit 40 Satellitenaufnahmen (zwei mal zwanzig Aufnahmedaten) kann in *Tabelle 1* eingesehen werden.

Die Doppelung im April 2019 führt daher, dass im Mai keine wolkenfreien Aufnahmen gemacht werden konnten und deshalb eine Aufnahme vom 30.04.2019 gewählt wurde, um die gleiche Menge an Aufnahmen zu liefern wie 2018. Ansonsten wurde versucht für die Zeiträume April bis September monatliche Aufnahmen für die Jahre 2018 und 2019 zu erhalten, um möglichst mehrstufige Änderungsprozesse einbeziehen zu können. 2020 dient mit einigen wenigen Aufnahmen als Vergleichs- und Resultatsjahr, hier werden aufgrund der angespannteren Situation entsprechende Werte erwartet, mit denen die Werte von 2018 und 2019 eingeordnet werden können.

Tabelle 1. Datengrundlage und Zeiträume der benutzten Sentinel-2-Daten [eigene Darstellung]

Monat	2018	2019	2020
Januar			x
Februar	x	x	
März			x
April	x	x x	
Mai	x		x
Juni	x	x	
Juli	x	x	
August	x	x	x
September	x	x	
Oktober			
November	x		x
Dezember			

Methodik

Die Programmiersprache R ist eine dynamische Sprache für statistische Berechnungen, die funktionale Merkmale und objektorientierte Programmierung mit einer einfach zu erlernenden Syntax kombiniert [Morandat et al. 2015]. Sie wird vor allem für statistische Berechnungen eingesetzt, kann aber durch ihre Kompatibilität und Offenheit gegenüber Objekten und Klassen auch für andere Zwecke eingesetzt werden. Mithilfe von sogenannten Packages, sprich Methodenbibliotheken, die sowohl von den Entwicklern selbst wie auch durch Privatentwickler angeboten werden, ist R flexibel erweiterbar und daher auch für geographische Zwecke nutzbar. Eines der prominentesten Packages in diesem Bereich ist `raster` (<https://cran.r-project.org/package=raster>), welches durch `terra` (<https://cran.r-project.org/package=terra>) mit erweiterten Methoden neu aufgesetzt und nach und nach ersetzt wird [Wimberly 2023]. Beide Packages bieten die Generierung von Stacks an, welche als Rasterdaten mit mehreren übereinander gelagerten Layern mit gleichem Extent genutzt werden können. Diese erlauben das Übereinanderlagern verschiedener Rasterdaten eines Gebiets mit mehreren Zeitpunkten, sodass so im Grunde Time-Series-Objekte, also Zeitreihen, erstellt werden können, die durch den Funktionsumfang von R frei verarbeitet und statistisch analysiert werden können. Als Datengrundlage für diese Objekte dienen Basis-Rasterdaten wie Satellitenaufnahmen und berechnete Rasterdaten wie Vegetationsindizes, was sie für die Anwendung im Rahmen dieses Projektes sehr nützlich machen. Die automatisierte Verarbeitung und Quantifizierung dieser Daten mit R ist der konkrete Anwendungsfall, wofür eine Methodik entwickelt wurde, die im folgenden näher beleuchtet wird und in Abbildung 7 eingesehen werden kann.

Bevor die heruntergeladenen Satellitendaten verwendet werden können, müssen sie üblicherweise vorprozessiert werden [Barta et al. 2021]. Dabei werden mittels Methoden aus dem `base` Package von R aus den Datenordnern die für die Berechnung des NDVI nötigen Bänder ausgelesen und mit dem `terra` Package zu Spatial-Rastern beziehungsweise Rasterstacks zusammengefügt. Dies ermöglicht die weitere gemeinsame Verarbeitung beider Bänder. Die Namen für die Layer der Rasterstacks werden mittels mitgelieferten Metadaten der Sentinel-2-Daten generiert, die für diesen Zweck nach spezifizierten Stichworten ausgelesen werden. Zudem werden die Rasterstacks mittels eigens erstellter Bounding Box mit dem Extent des Harz ausgeschnitten, um Datenmengen zu sparen und die Daten auf das zu analysierende Gebiet zu fokussieren. Üblicherweise werden die Rasterstacks anschließend mit einer Wolkenmaske wie oben beschrieben bereinigt, um verdeckte Pixel aus den Datensätzen zu entfernen, da sie die Daten verfälschen könnten [Barta et al. 2021, Stych et al. 2019]. Aus oben genannten Gründen und der erreichten vorliegenden Datengüte durch die manuelle Aussicht der Daten wurde dieser Schritt übersprungen.

Mit den resultierenden Rasterstacks mit jeweils zwei Bändern wird nun der NDVI mittels oben genannter Formel errechnet und als TIF-Datei abgespeichert. Da Daten aus zwei Tiles vorliegen, werden die TIF-Dateien gruppierend nach Aufnahmedatum wieder zusammengefügt. Dies sind die ersten Ergebnisdaten, da diese nach Visualisierung in einem Plot bereits erste qualitative Analysen der NDVI-Veränderungen über die Zeit zulassen. Sie werden in einem nächsten Schritt zur zusätzlichen genaueren Analyse mit den Extents der zwei AOIs ausgeschnitten, sodass die Vorprozessierung dann mit diesem Schritt abgeschlossen ist, da die entsprechenden Datengrundlagen für die Analyse vorliegen.

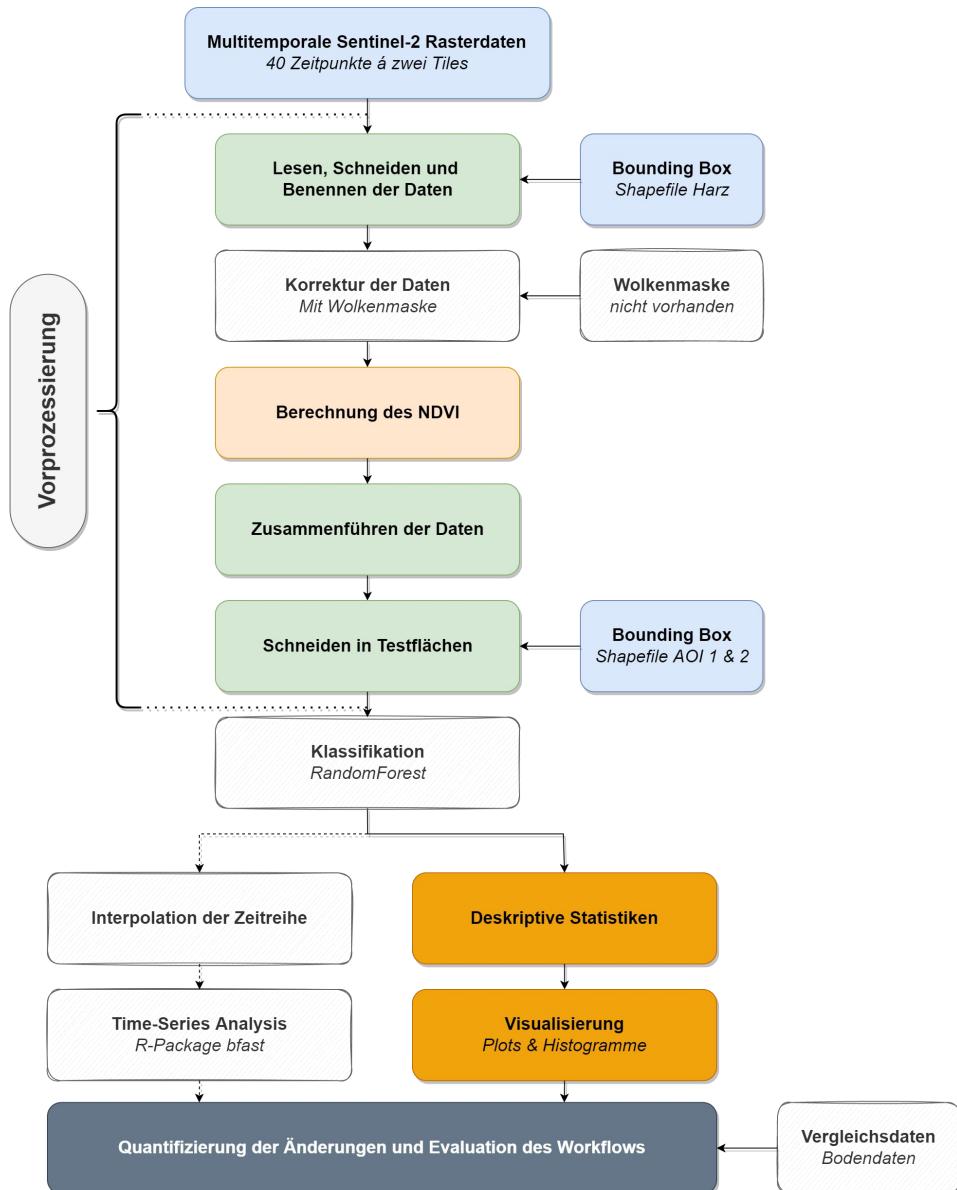


Abbildung 7. Workflow des Projektes. Hellblaue Elemente zeigen Daten und Inputs, ausgegraute Elemente zeigen geplante nicht eingesetzte Tools/Schritte [eigene Darstellung]

Für inhomogene Datensätze und Gebiete, in dem Fall Wälder also Gebiete mit Mischwald oder verschiedenen störenden Elementen, die die Datenqualität beeinflussen, sollte eine (semi-)überwachte ((semi-)supervised) Klassifikation wie Random-Forest folgen, um entsprechende Klassen mit den Versuchsstoffen zu bilden und Falschdaten zu minimieren [Barta et al. 2021, Fernandez-Carrillo et al. 2020, Minarik et al. 2021]. Allerdings ist eine Klassifikation in diesem Fall nicht nötig, da in den AOIs Fichten den absoluten Hauptteil der Vegetation ausmachen und Neutralisierungseffekte weder unter den Nadelbäumen an sich noch bei Nichtbaumpixeln, in diesem Fall vornehmlich Waldwege, auftreten. Außerdem werden vor allem relative Veränderungen eruiert werden, daher wurde die Klassifikation ausgelassen und alle Pixel in den AOIs in den anschließenden Analysen verwendet.

Ab diesem Punkt werden wie im Workflow in Abbildung 7 zu sehen zwei parallele Methodiken zur eigentlichen Analyse eingesetzt. Zum Einen sollen Veränderungen des NDVI über die Zeit für die beiden AOIs wie bei Stych et al. [2019] durch die Erstellung von deskriptiven Statistiken und deren Visualisierung mittels der Packages `ggplot2` (<https://cran.r-project.org/package=ggplot2>) und `rasterVis` (<https://cran.r-project.org/package=rasterVis>) durch Plots und Histogramme qualitativ und quantitativ gezeigt werden, zum Anderen wäre für eine längerfristige Zeitreihe ohne bekannten Ausbruchszeitpunkt das Package `bfast` (<https://cran.r-project.org/package=bfast>) zum Einsatz gekommen, welches Zeitpunkte signifikanter Änderungen in den Werten, wie sie zum Beispiel nach Waldbränden oder Flutkatastrophen auftreten, bestimmen

kann. Dies hat allerdings für gegebene Daten nicht geklappt, da die Zeitreihe wahrscheinlich einerseits zu kurz ist und so das Modell nicht ausgiebig trainiert werden kann und andererseits ein Befall mit Borkenkäfern kein abruptes Ereignis ist, sondern sich über mehrere Monate bis hin zu Jahren ziehen kann [Barta et al. 2021, Marvasti-Zadeh et al. 2022]. Es wird empfohlen, die Daten vor dem Nutzen des Modells zu interpolieren, damit Daten mit gleichmäßigen Abständen vorliegen. Mit der Methode `bfastlite` aus dem Package `bfast` könnten nicht vorhandene Werte zwar übersprungen werden, das geht aber mit den anderen Methoden nicht, da ist eine vorherige Interpolation zwingend erforderlich. Da die Time-Series-Analysis mit `bfast` zusätzlich zu den deskriptiven Statistiken den Rahmen dieser Arbeit gesprengt hätte, wurde dieser Weg nur der Vollständigkeit halber dem Workflow hinzugefügt mit der Empfehlung diesen ebenfalls zu wählen, wenn entsprechende Fragestellungen und Datensätze vorliegen und ein ähnlicher Workflow verfolgt wird.

Schließlich werden die Histogramme, Plots und Statistiken interpretiert und ein Vergleich zwischen den beiden AOIs durchgeführt, sodass Aussagen bezüglich ungewöhnlicher Änderungen der NDVI-Werte getroffen werden können. Mithilfe von externen Vergleichsdaten wie Bodendaten könnten so bestimmte Flächen mit bestimmten Schädlingen oder Prozessen in Verbindung gebracht und das Wissen für andere Anwendungen wiederverwendbar gemacht werden. Eine Evaluation des Workflows soll zum Ende hin aufzeigen, welche Möglichkeiten die automatisierte Zeitreihenanalyse mit R bietet.

ERGEBNISSE

Die Tabelle in *Anhang 2* zeigt die deskriptiven Statistiken, die nach dem Durchlaufen des R-Scripts ausgegeben wurden, aufgeschlüsselt nach Aufnahmedatum und aufgeteilt auf die beiden AOIs. Zu sehen sind in erster Linie ähnliche Werte im Vergleich der beiden AOIs, wobei es immer wieder kleinere Unterschiede gibt. Die größten Unterschiede weisen vor allem die Mittelwerte 2020 in AOI 2 auf, dort ist die Standardabweichung auch mit am höchsten. Generell scheint keine Fläche besonders ausgeprägte Werte bis auf diese aufzuzeigen. Auffällig ist zudem, dass es scheinbare Trends über die Jahre zu geben scheint, da sich die Werte von Jahr zu Jahr unterscheiden, bei beiden AOIs.

Die folgenden Abbildungen wurden vor allem zur Visualisierung der beschriebenen Tabellendaten erstellt und zeigen die in der Tabelle und in den Plots vermuteten Trends zwischen den Aufnahmepunkten. Alle Abbildungen wurden auf den Wertebereich von -0,2 bis 1 geschnitten, damit vor allem Unterschiede in den Vegetationen klarer werden und Werte unter 1 generell die Abwesenheit von Vegetation anzeigen [Jensen 2007].

Folgende Plots zeigen visuell den Verlauf der NDVI-Werte über die Zeit je nach AOI. *Abbildung 8* zeigt die Werte für den gesamten Harz. Hier ist zu sehen, dass die Saisonalität im Umland gut durch den NDVI sichtbar wird, da in den Wintermonaten die NDVI-Werte im gesamten Harz niedriger sind als in den Sommermonaten. Typisch für Nadelwälder verändern sich die Werte für den Wald an sich aber über das Jahr nicht so stark. Zudem sind keine großen Schadensflächen zu erkennen, aber das soll anhand der AOIs näher beleuchtet werden, da hier auch der Maßstab keine genauen Sichtungen zulässt.

Anhang 3 zeigt die Wertverläufe für die beiden AOIs. Beide zeigen wie auch in den Tabellendaten viele Ähnlichkeiten und einen ähnlichen Wertverlauf. Unterschiede werden erst 2020 sichtbar, hier gibt es größere Flächen in AOI 2, die niedrigere Werte aufweisen als in AOI 1, dort sind solche Flächen nicht zu sehen. Die Werte im Januar/Februar und November sind die niedrigsten in beiden AOIs, wobei Januar 2020 die scheinbar niedrigsten aufweist. Die Sommermonate Juni und Juli zeigen die höchsten Werte, allerdings sind die von 2018 am höchsten und in den Folgejahren niedriger. Bei AOI 2 ist die Fläche in der südwestlichen Region ab August 2019 interessant, hier nehmen die Werte stetig ab und steigen nicht wieder.

Anhang 4 zeigt die Wertebereiche der Plots als Histogramme, damit die Verteilung der Werte sichtbarer wird. Grundsätzlich sind die Verteilungen auch hier ähnlich mit einigen kleineren Nebenpeaks neben den Mittelwerten und Peaks der Verteilungen, doch hier wird sichtbar, was in den Plots bereits als Flächen niedriger Werte in AOI 2 vermutet wurde. Vor allem in 2020 weist AOI 2 wesentlich mehr niedrigere Werte und andere Verteilungen auf. Besonders hervorzuheben ist auch der Wertebereich um NDVI 0,3, hier unterscheiden sich die beiden AOIs am meisten. Ansonsten bewegt sich der Großteil der Verteilungen stets im Bereich um NDVI 0,8. Die größte Besonderheit bildet das Jahr 2020 in AOI 2, hier ist die Verteilung anders als in den beiden anderen Jahren in beiden AOIs, es sind nämlich zwei Verteilungsspitzen bestimmt.

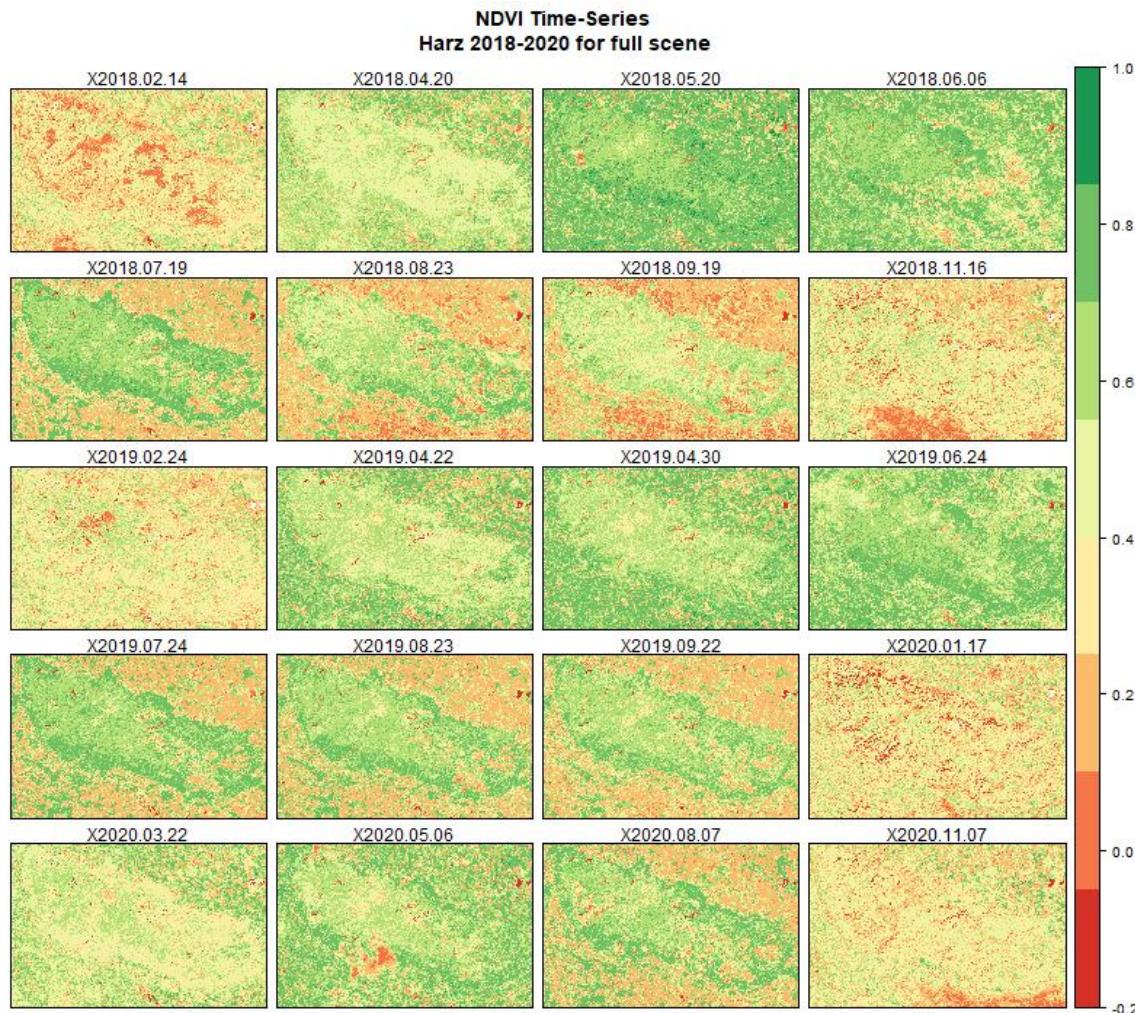


Abbildung 8. Plot der Zeitreihe der NDVI-Werte 2018-2020, ganzer Harz [eigene Darstellung]

Um einen besseren Vergleich der Werte zu schaffen, wurden die Werte als Crossbarplot dargestellt. Das sind abgespeckte Boxplots, da sie nicht mit allen Werten, sondern mit den bereits errechneten Minima, Maxima und Mittelwerten erstellt werden. *Abbildung 9* zeigt diese für beide AOIs. Der Verlauf der Werte ist auch hier ähnlich. Interessant ist hierbei, dass im Vergleich zur AOI 1 die Werte in AOI 2 zwischen 2018 und 2019 näher aneinander liegen, die Veränderungen im Mittelwert also scheinbar geringer sind. In 2019 sind im Juni in AOI 1 niedrigere Werte festzustellen. In *Anhang 3* kann dies auch gesehen werden, da fehlen bei AOI 1 tief grün gefärbte Flächen wie bei AOI 2. Ebenfalls in *Abbildung 9* zu sehen sind verschiedene Werte für 2020, wie das auch in den Histogrammen in *Anhang 4* schon der Fall war. Diese Auffälligkeit wird in *Abbildung 10* bestätigt, hier werden die Mittelwerte der Zeitpunkte über die Jahre übereinander gelagert gezeigt. Hier wird nochmal deutlich, dass sie über die Jahre gerade im Sommer abnehmen, wobei der Unterschied in AOI 2 zwischen 2019 und 2020 größer ausfällt. Gut zu sehen ist hier auch die oben angesprochene Saisonalität, die durch die Maxima in den Sommermonaten in 2018 dargestellt werden. In den anderen Jahren fällt sie nicht so auf, ist aber auch in den Diagrammen wahrnehmbar.

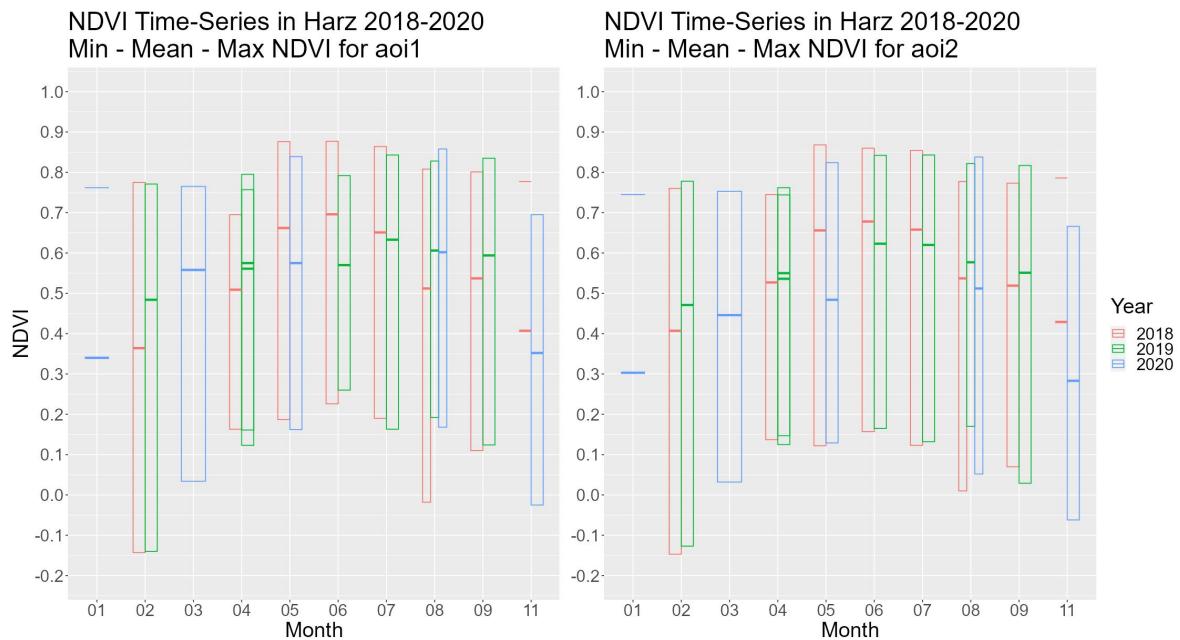


Abbildung 9. Crossbarplot mit Minima, Maxima und Mittelwerten der Zeitreihe der NDVI-Werte 2018-2020, links: AOI 1 und rechts: AOI 2 [eigene Darstellung]

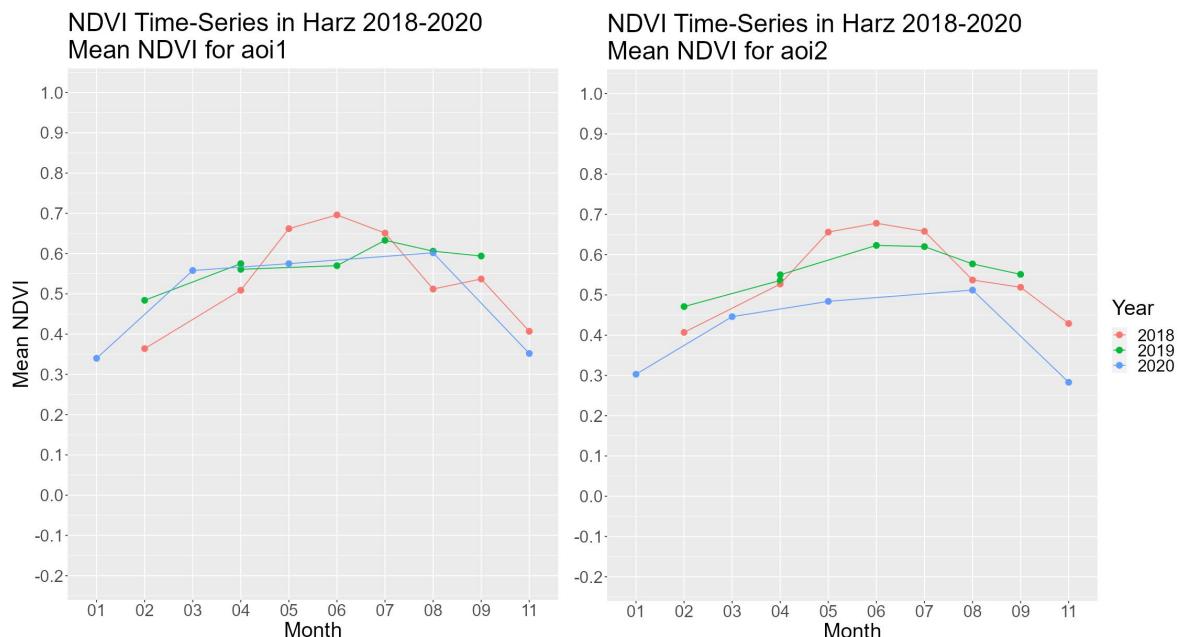


Abbildung 10. Liniendiagramm mit Mittelwerten der Zeitreihe der NDVI-Werte 2018-2020, links: AOI 1 und rechts: AOI 2 [eigene Darstellung]

DISKUSSION

Basierend auf den Plots ist auszusagen, dass die Saisonalität in der Vegetation durch den NDVI gut abgebildet wird. Gerade der Unterschied zwischen dem späten Sommer und dem tiefen Herbst beziehungsweise Winter stellt große Veränderungsprozesse dar, die sich dann im Frühjahr wieder erholen. Dabei ist anzumerken, dass die gewählten Aufnahmezeitpunkte gut zur Erfassung der Saisonalität geeignet sind, wie Senf et al. [2017] empfohlen haben. Die Saisonalität ist auch in den Histogrammen sichtbar, hier verlagert sie die Häufigkeiten in die niedrigeren NDVI-Bereiche. Interessant ist hierbei das Jahr 2020 im Vergleich zu 2018 und 2019, denn hier werden sogar zweite Häufigkeitsspitzen im niedrigen NDVI-Bereich ausgebildet. Was hier stark für eine untypische Veränderung spricht ist die zweite Spitze im Bereich NDVI 0,2 im Histogramm im Januar 2020 in

AOI 2, denn diese Spitze erholt sich als einzige im Frühjahr nicht und ist auch im Sommer noch nachweisbar, zwar nicht so ausgeprägt, aber doch wesentlich stärker als in AOI 1 und den Vorjahren. Einzelne untypische Messungen an einzelnen Aufnahmedaten sprechen in erster Linie für Wolken [Barta et al. 2021], ziehen sich diese Effekte aber über mehrere Aufnahmen, liegt eine Änderung in der Vegetation vor. Ein NDVI-Wert um 0,2 deutet auf sehr trockene Vegetation hin [Konecny 2014], daher ist anzunehmen, dass hier Waldflächen zu Schaden gekommen sind. Wird diese Spitze in den Fokus gesetzt und in den Histogrammen gesucht, kann sie bis Februar 2019 zurückverfolgt werden. Werden zusätzlich die Plots hinzugenommen und auch dort der Fokus auf eine Fläche gelegt, die niedrige Werte ausbildet und diese sich nicht erholen, kann die bereits angesprochene südwestliche Region in AOI 2 bis auf September 2018 zurückdatiert werden. Ab diesem Zeitpunkt verändert sich diese Region anders als die restlichen Regionen in AOI 1 und 2, die NDVI-Werte nehmen früher zum Winter hin ab und die Fläche bleibt auch im Sommer im mittleren bis niedrigen NDVI-Wertebereich.

Dass der Verlauf untypisch ist, ist durch die Prozesse in 2018 zu sehen, dort tritt diese Fläche nicht in dieser Form in Erscheinung. Es ist also anzunehmen, dass hier möglicherweise ein Befall von Schädlingen vorliegt oder ein anderes Ereignis eingetreten ist, welches das Waldwachstum stagnieren lässt, ähnliche Rückschlüsse wie bei Abdullah [2019] und Gomez et al. [2020]. Dass eine gewisse Wahrscheinlichkeit für einen Befall vorliegt, zeigen Overbeck et al. [2011] für den Westharz und AOI 1. Hier liegt die Wahrscheinlichkeit zwischen 21 bis 40 %, was darauf rückschließen lässt, dass es im Ostharp nicht anders sein müsste, da dort die geographischen Rahmenbedingungen nicht groß anders sind. An dieser Stelle wären Bodendaten zum Vergleich sehr hilfreich gewesen, um die Dynamiken besser einordnen zu können, wie es bei Abdullah [2019] und Barta et al. [2021] gehandhabt wurde.

Werden Plots, Histogramme und Diagramme miteinander verglichen, wird klar, dass alle auf Basis der gleichen Werte unterschiedliche Aussagen erlauben und daher die Mischung aus allen sehr gut geeignet ist, um einen Überblick über die AOIs und die Prozesse im Waldwachstum zu erhalten. Kein Wert kann ohne die weiteren betrachtet werden, da dieser immer in Verhältnis gesetzt werden muss und die absoluten Werte in Anbetracht der Flächenbeschaffenheit weniger Aussagekraft besitzen als relative Veränderungen. Dahingehend ist es sehr sinnvoll, nicht nur deskriptive Statistiken zu erfassen, sondern diese auch entsprechend zu visualisieren. Studien wie Latifi et al. [2014] zeigen zudem, wie fernerkundliche Zeitreihenanalysen von früheren bestätigten Fällen Aufschluss über heutige und künftige Entwicklungen geben können. Studien wie Fernandez-Carrillo et al. [2020] und Minarik et al. [2021] zeigen Methoden, wie die erhobenen Daten durch Klassifikation mit anschließendem Accuracy Assessment in Rasterkarten transferiert werden können, welche direkt dem Waldmonitoring zugute kommen können. Wie Senf et al. [2017] aber ansprechen, sind kleinräumige Analysen zwar gut für das Waldmonitoring und damit eine gute Ergänzung zum manuellen Befallsmonitoring, sie sind aber nicht gut dafür geeignet sind, Schädlingsbefälle zu verstehen und langfristig und nachhaltig prognostizieren zu können. Hier müssen mehr hochauflösende großflächige Analysen mit langen Zeitreihen erfolgen, was allerdings viel Rechenleistung und einen gut strukturierten automatisierten Workflow benötigt, wie ihn Abdullah [2019] konzipiert hat. Hier werden neben der Erfassung der genannten Daten auch statistische Tests sowie Ground Truthing Maßnahmen genutzt, um die Daten weiter zu eruieren. Solch ein Workflow angewendet auf die Empfehlungen von Senf et al. [2017] könnte der Forstschädlingsthematik große wissenschaftliche Fortschritte bringen. Dabei sollte allerdings auch beachtet werden, dass nicht alle Schädlinge ausschließlich Schaden anrichten. Durch gezielte Verwertungsprozesse bilden sie einen natürlichen Selektions- und Regulierungsmechanismus, der dem Waldwachstum wie Davis et al. [2020] und Beudert et al. [2014] erläutern auch nützen kann. Die Debatte um den Umgang mit den Schädlingen und vor allem ihres durch den Klimawandel zunehmenden Aufkommens muss also unter Anbetracht vieler weiterer Faktoren weitergeführt und die Forschung auf beide Seiten gerichtet werden.

FAZIT

Die hier erfolgte deskriptiv-statistische Zeitreihenanalyse hat gezeigt, dass multispektrale Rasterdaten große Potenziale zur Quantifizierung von natürlichen und untypischen Prozessen auf der Erdoberfläche mitbringen. Je nach Aufnahmemedium können unterschiedliche Ziele verfolgt und unterschiedliche Daten aufgenommen und verwertet werden. Werden die richtigen Methoden angewandt, können nicht nur visuelle Darstellungen durch Einfärben der Plots gestaltet werden, sondern auch Zellstatistiken erhoben werden, die durch statistische Verfahren quantifiziert und evaluiert werden können. Dadurch sind gezielte Aussagen über Prozesse und das Erscheinungsbild der Erde wie in dieser Arbeit, wo eine mögliche Befallsfläche eines Schädlingsbefalles im Harzer Wald bestimmt wurde, möglich.

Werden Daten zusammengeführt, können so noch mehr Informationen erlangt werden und wie in diesem Fall das Waldmonitoring durch sinnvolle Daten erweitert und effizienter gestaltet werden. Der wichtigste Punkt im Umgang mit Rasterdaten und Rasterzeitreihen ist die Datengüte, hier muss bereits im Vorfeld hinreichend gewährleistet werden, dass sie für die Analyse ausreichen und gute Ergebnisse liefern können. Durch Toolsets

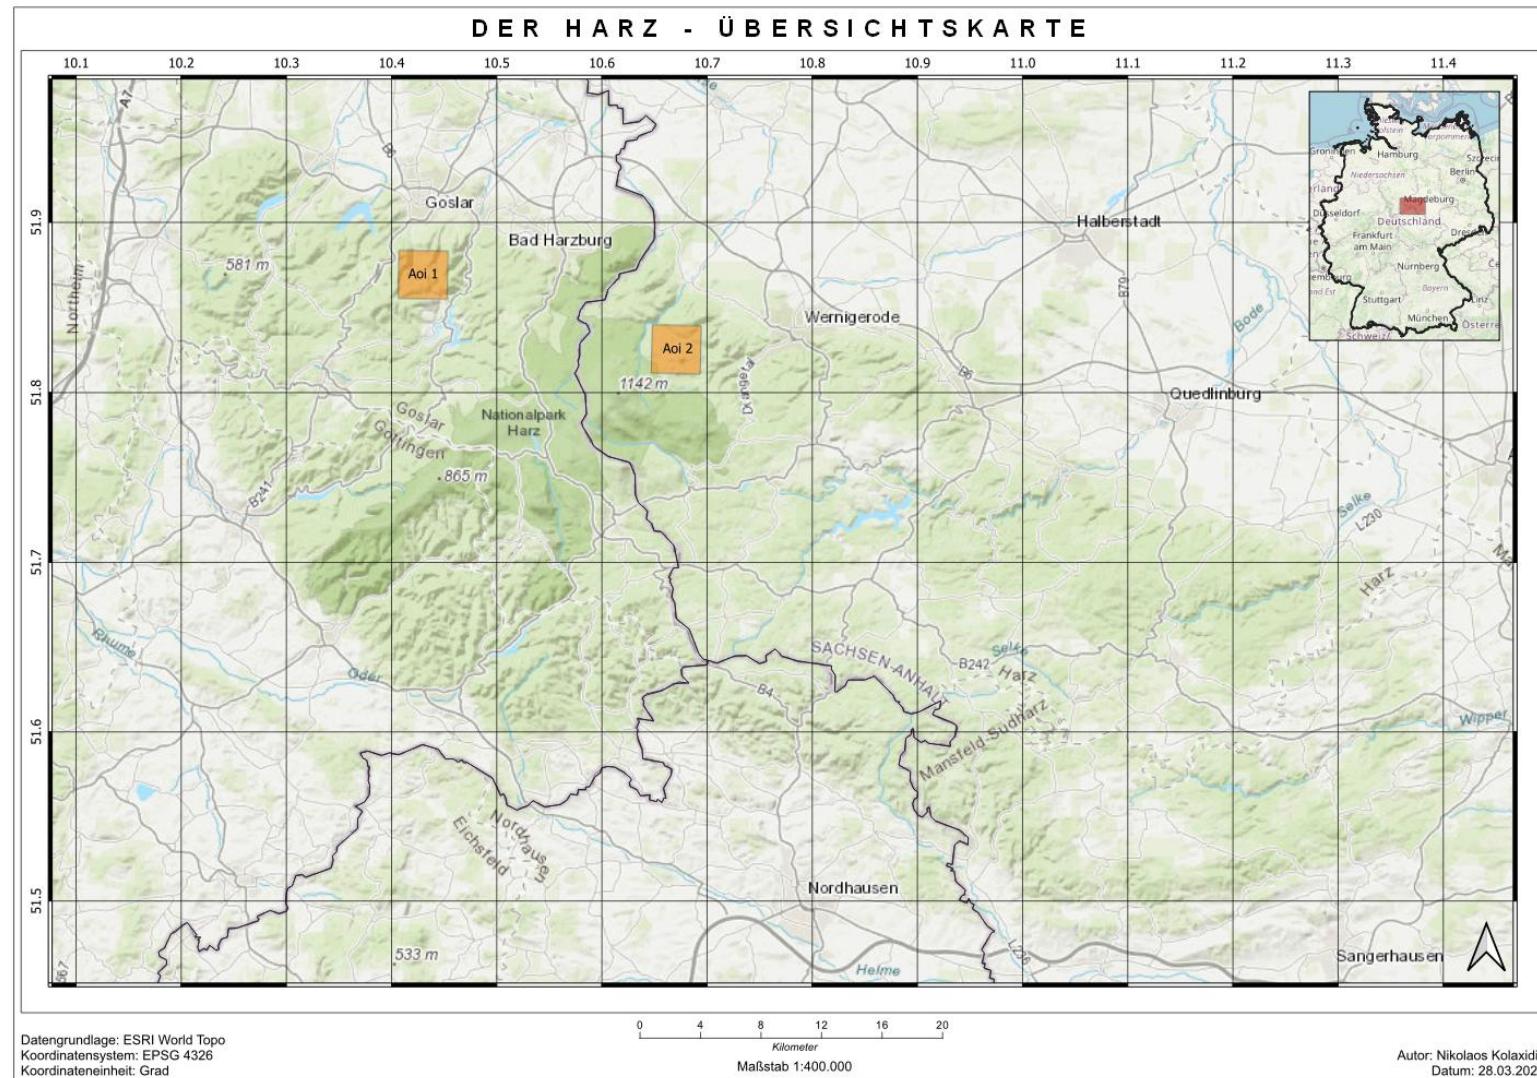
und Methoden zur Korrektur der Daten wie Wolkenmasken, zur Klassifikation von Datenpunkten wie RandomForest und zur eigentlichen Zeitreihenanalyse wie das R-Package `bfast` können diverse Ergebnisse geliefert und Schlüsse gezogen werden. Diese Arbeit ist ein kleiner Einblick in die automatisierte fernerkundliche Zeitreihenanalyse mit R und gibt einige Vorschläge für mögliche weitere Anwendungsgebiete und Fragestellungen.

LITERATURVERZEICHNIS

- Abdullah, H.J. (2019): Remote Sensing of European Spruce (*Ips Typographus*, L.) Bark Beetle Green Attack. Dissertation, Universität Twente.
- Aryal, J., Sitaula, C., Aryal, S. (2022): NDVI Threshold-Based Urban Green Space Mapping from Sentinel-2A at the Local Governmental Area (LGA) Level of Victoria, Australia. *Land*, 11:351.
- Barta, V., Lukes, P., Homolova, L. (2021): Early detection of bark beetle infestation in Norway spruce forests of Central Europe using Sentinel-2. *International Journal of Applied Earth Observations and Geoinformation*, 100:102335.
- Beudert, B., Bässler, C., Thorn, S., Noss, R., Schröder, B., Dieffenbach-Fries, H., Foullois, N., Müller, J. (2014): Bark Beetles Increase Biodiversity While Maintaining Drinking Water Quality. *Conservation Letters*, 00(0):1.
- BMEL [Bundesministerium für Ernährung und Landwirtschaft] (2023): Ergebnisse der Waldzustandserhebung 2022. Paderborn.
- Bundeswaldinventur (2017): Waldfläche nach Land und Waldspezifikation. Ergebnisdatenbank ([https://bwi.info/inhalt1.3.aspx?Text=1.02%20Waldfläche%20\[ha\]%20nach%20Waldspezifikation&prrole=public&prInv=THG2017&prKapitel=1.02&mpXicode=](https://bwi.info/inhalt1.3.aspx?Text=1.02%20Waldfläche%20[ha]%20nach%20Waldspezifikation&prrole=public&prInv=THG2017&prKapitel=1.02&mpXicode=)) [27.03.2023].
- Davis, T.S., Rhoades, P.R., Mann, A.J., Griswold, T. (2020): Bark beetle outbreak enhances biodiversity and foraging habitat of native bees in alpine landscapes of the southern Rocky Mountains. *Scientific Reports*, 10:16400.
- DWD [Deutscher Wetterdienst] (2021): Klimastatusbericht Deutschland. Jahr 2020. Deutscher Wetterdienst, Offenbach.
- DWD [Deutscher Wetterdienst] (2023): Klimawandel - ein Überblick (https://www.dwd.de/DE/klimaumwelt/klimawandel/klimawandel_node.html) [27.03.2023].
- ESA [European Space Agency] (2022a): Resolution and Swath, Spatial and Spectral Resolutions (<https://sentinel.esa.int/web/sentinel/missions/sentinel-2/instrument-payload/resolution-and-swath>) [25.03.2023].
- ESA [European Space Agency] (2022b): Level-1C Masks (<https://sentinel.esa.int/web/sentinel/technical-guides/sentinel-2-msi/level-1c/masks>) [25.03.2023].
- Fernandez-Carrillo, A., Patocka, Z., Dobrovolny, L., Franco-Nieto, A., Revilla-Romero, B. (2020): Monitoring Bark Beetle Forest Damage in CentralEurope. A Remote Sensing Approach Validated with Field Data. *Remote Sensing*, 12:3634.
- Frampton, W.J., Dash, J. Watmough, G., Milton, E.J. (2013): Evaluating the capabilities of Sentinel-2 for quantitative estimation of biophysical variables in vegetation. *Journal of Photogrammetry and Remote Sensing*, 82:83.
- Ghazaryan, G., Dubovyk, O., Graw, V., Kussul, N., Schellbergd, J. (2020): Local-scale agricultural drought monitoring with satellite-based multi-sensor time-series. *GIScience & Remote Sensing*, 57 (5):704.
- Gomez, D.F., Ritger, H.M.W., Pearce, C., Eickwort, J., Hulcr, J. (2020): Ability of Remote Sensing Systems to Detect Bark Beetle Spots in the Southeastern US. *Forests*, 11:1167.
- Gross, D. (2005): Monitoring Agricultural Biomass Using NDVI Time Series. *Food and Agriculture Organization of the United Nations (FAO)*, Rome, Italy.
- Hadoux, X. (2014): Some Contributions to Supervised Classification of Hyperspectral Data, Dissertation, University of Montpellier.
- IPCC [Intergovernmental Panel on Climate Change] (2015): Climate Change 2014. Synthesis Report. Genf, Schweiz.
- Isioye, O., Akomolafe, E., Awulu, J. (2020): Geospatial analysis of Impervious Surfaces and their Effect on Land Surface Temperatur in Abuja, Nigeria. *International Archives of the Photogrammetry Remote Sensing and Spatial Information Sciences*, 44-3/W1-2020.
- Jensen, J.R. (2007): Remote Sensing of the Environment. An Earth Resource Perspective. Second Edition. Pearson Education, Noida, New Delhi, Indien.
- Kautz, M., Meddens, A.J.H., Hall, R.J., Arneth, A. (2017): Biotic disturbances in Northern Hemisphere forests –

- a synthesis of recent data, uncertainties and implications for forest monitoring and modelling. *Global Ecology and Biogeography*, 26:533.
- Konecny, G. (2014): Geoinformation. Remote Sensing, Photogrammetry, and Geographic Information Systems. Second Edition. CRC Press, Boca Raton, Vereinigte Staaten von Amerika.
- Latifi, H., Schumann, B., Kautz, M., Dech, S. (2014): Spatial characterization of bark beetle infestations by a multiday synergy of SPOT and Landsat imagery. *Environmental Monitoring and Assessment*, 186:441.
- Lilienthal, H. (2014): Optische Sensoren in der Landwirtschaft: Grundlagen und Konzepte. *Journal für Kulturpflanzen*, 66 (2):34.
- LPIMIC [Linus Pauling Institute's Micronutrient Information Center] (2022): α-Carotene, β-Carotene, β-Cryptoxanthin, Lycopene, Lutein, and Zeaxanthin (<https://lpi.oregonstate.edu/mic/dietary-factors/phytochemicals/carotenoids>) [25.03.2023].
- Marvasti-Zadeh, S.M., Goodman, D., Ray, N., Erbilgin, N. (2022): Early Detection of Bark Beetle Attack Using Remote Sensing and Machine Learning. A Review. ArXiv, 1:1.
- Minarik, R. Langhammer, J. Lendzioch, T. (2021): Detection of Bark Beetle Disturbance at Tree Level Using UAS Multispectral Imagery and Deep Learning. *Remote Sensing*, 13:4768.
- Mondal, B.P. (2018): Hyper-Spectral Analysis of Soil Properties for Soilmanagement. *Advances in Agriculture for Sustainable Development*, Srijan Samit, Karkamatta, India.
- Morandat, F., Hill, B., Osvald, L., Vitek, J. (2015): Evaluating the Design of the R Language. *ECOOP 2012 – Object-Oriented Programming. ECOOP 2012. Lecture Notes in Computer Science*, 7313:104.
- Nationalpark Harz (2021): Tätigkeitsbericht 2020. Nationalpark Harz, Wernigerode, Deutschland.
- NASA [National Aeronautics and Space Administration] (2022a): Landsat 8 (<https://landsat.gsfc.nasa.gov/satellites/landsat-8/>) [25.03.2023].
- NASA [National Aeronautics and Space Administration] (2022b): Specifications, Moderate Resolution Imaging Spectroradiometer (<https://modis.gsfc.nasa.gov/about/specifications.php>) [25.03.2023].
- Overbeck, M., Schmidt, M. (2011): Modelling infestation risk of Norway spruce by Ips typographus (L.) in the Lower Saxon Harz Mountains (Germany). *Forest Ecology and Management*, 266:115.
- Rouse, J.W., Haas, R.H., Schell, J.A., Deering, D.W. (1974): Monitoring Vegetation Systems in the Great Plains with ERTS. *Third Earth Resources Technology Satellite-1 Symposium*, NASA SP-351, 1:309.
- Seidl, R., Thom, D., Kautz, M., Martin-Benito, D., Peltoniemi, M., Vacchiano, G., Wild, J., Ascoli, D., Petr, M., Honkaniemi, J., Lexer, M.J., Trotsiuk, V., Mairotta, P., Svoboda, M., Fabrika, M., Nagel, T.A., Reyer, C.P.O. (2017): Forest disturbances under climate change. *Nature Climate Change*, 7:395.
- Senf, C., Seidl, R., Hostert, P. (2017): Remote sensing of forest insect disturbances: Current state and future directions. *International Journal of Applied Earth Observation and Geoinformation*, 60:49.
- Spektrum Akademischer Verlag (1999): Forstsäädlinge. Lexikon der Biologie (<https://www.spektrum.de/lexikon/biologie/forstschaedlinge/25063>) [13.03.2023].
- Statista (2023): Anteil der Waldfläche in Deutschland in den Jahren von 2008 bis 2021 (<https://de.statista.com/statistik/daten/studie/1181669/umfrage/anteil-der-waldflaeche-in-deutschland/>) [27.03.2023].
- Sternal, B. (2020): Der Harzwald. Ein Ökosystem stellt sich vor. Sternal Media, Gernrode, Deutschland.
- Stych, P., Lastovicka, J., Hladky, R., Paluba, D. (2019): Evaluation of the Influence of Disturbances on Forest Vegetation Using the Time Series of Landsat Data. A Comparison Study of the Low Tatras and Sumava National Parks. *International Journal of Geo-Information*, 8:71.
- Watanabe, M., Ohishi, S., Pott, A., Hardbicker, U., Aoki, K., Sakagami, N., Ohta, H., Fujitake, N. (2004): Soil Chemical Properties and Distribution of Sclerotium Grains in Forest Soils, Harz Mts., Germany. *Journal of Soil Science and Plant Nutrition*, 50(6):863.
- Welle, T., Aschenbrenner, L., Kuonath, K., Kirmaier, S., Franke, J. (2022): Mapping Dominant Tree Species of German Forests. *Remote Sensing*, 14:3330.
- Wimberly, M.C. (2023): Geographic Data Science with R: Visualizing and Analyzing Environmental Change. Chapman & Hall/CRC, unpublished online version (<https://www.bookdown.org/mcwimberly/gdswr-book/>).

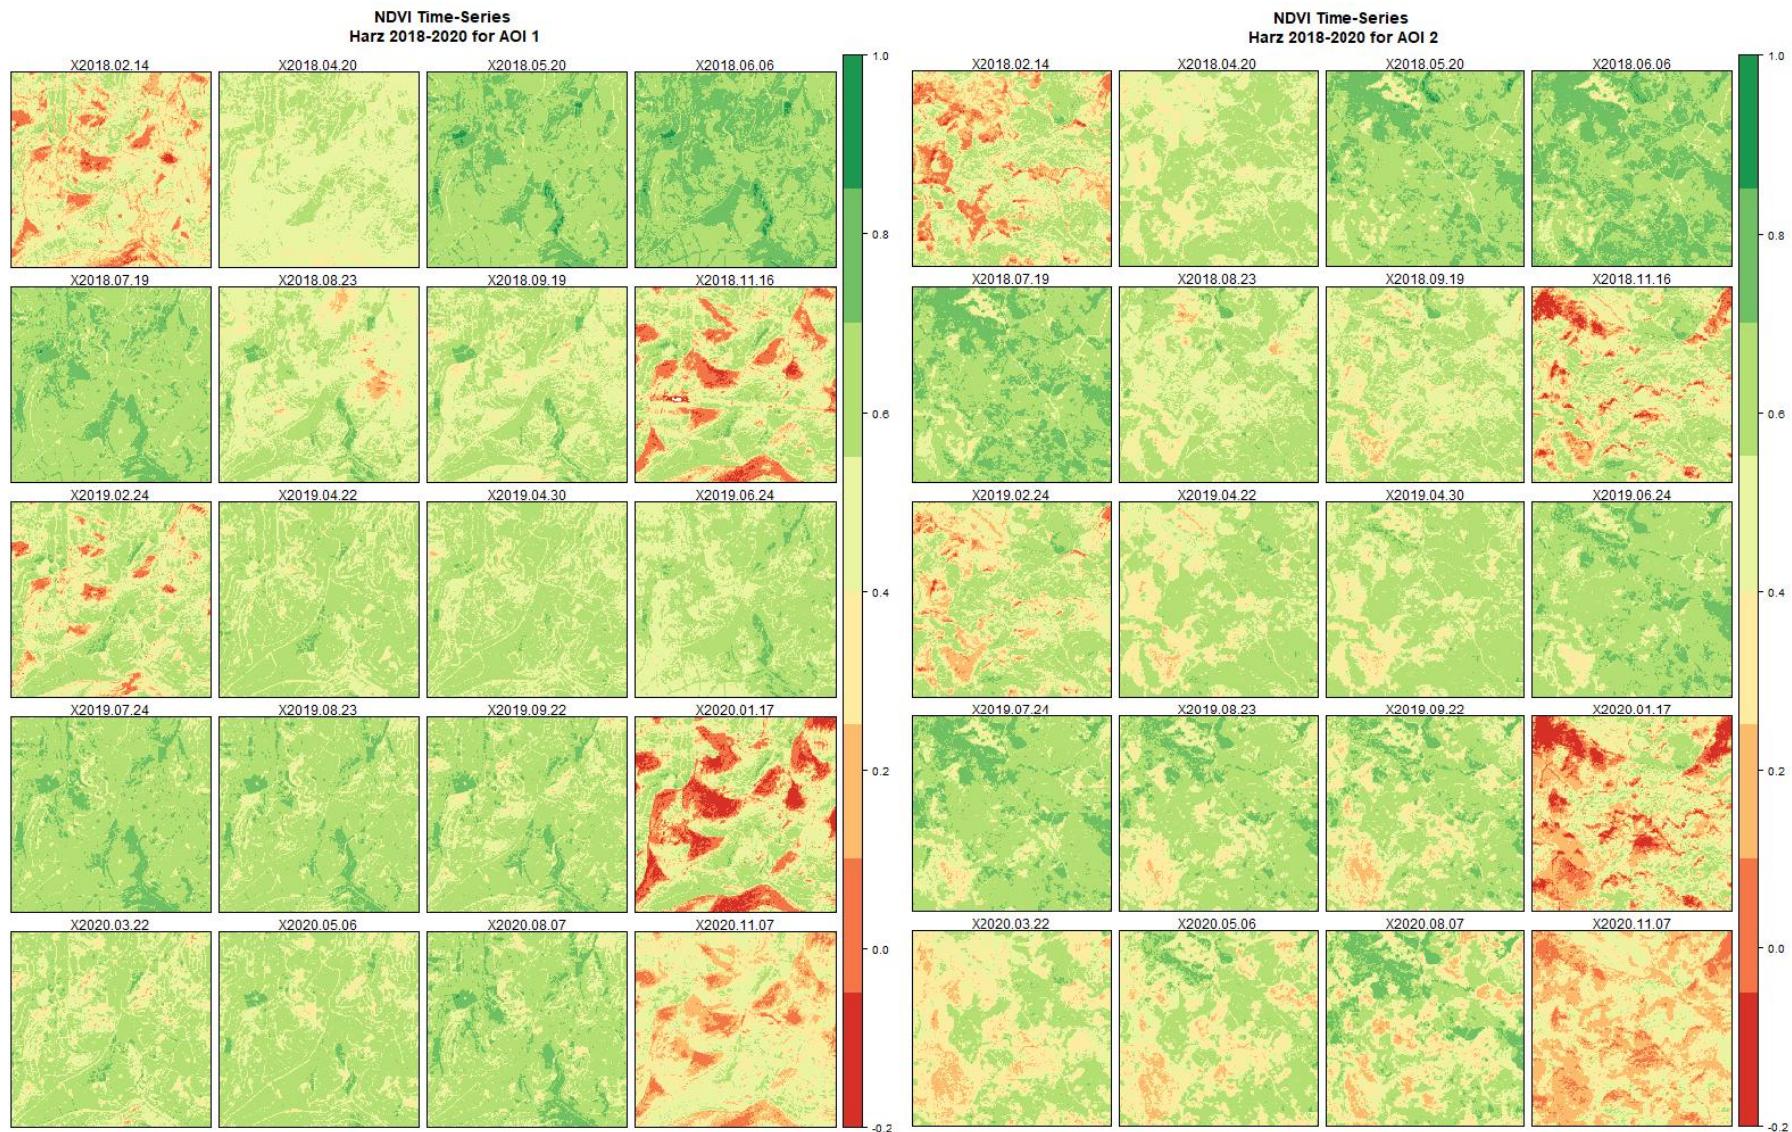
ANHANG



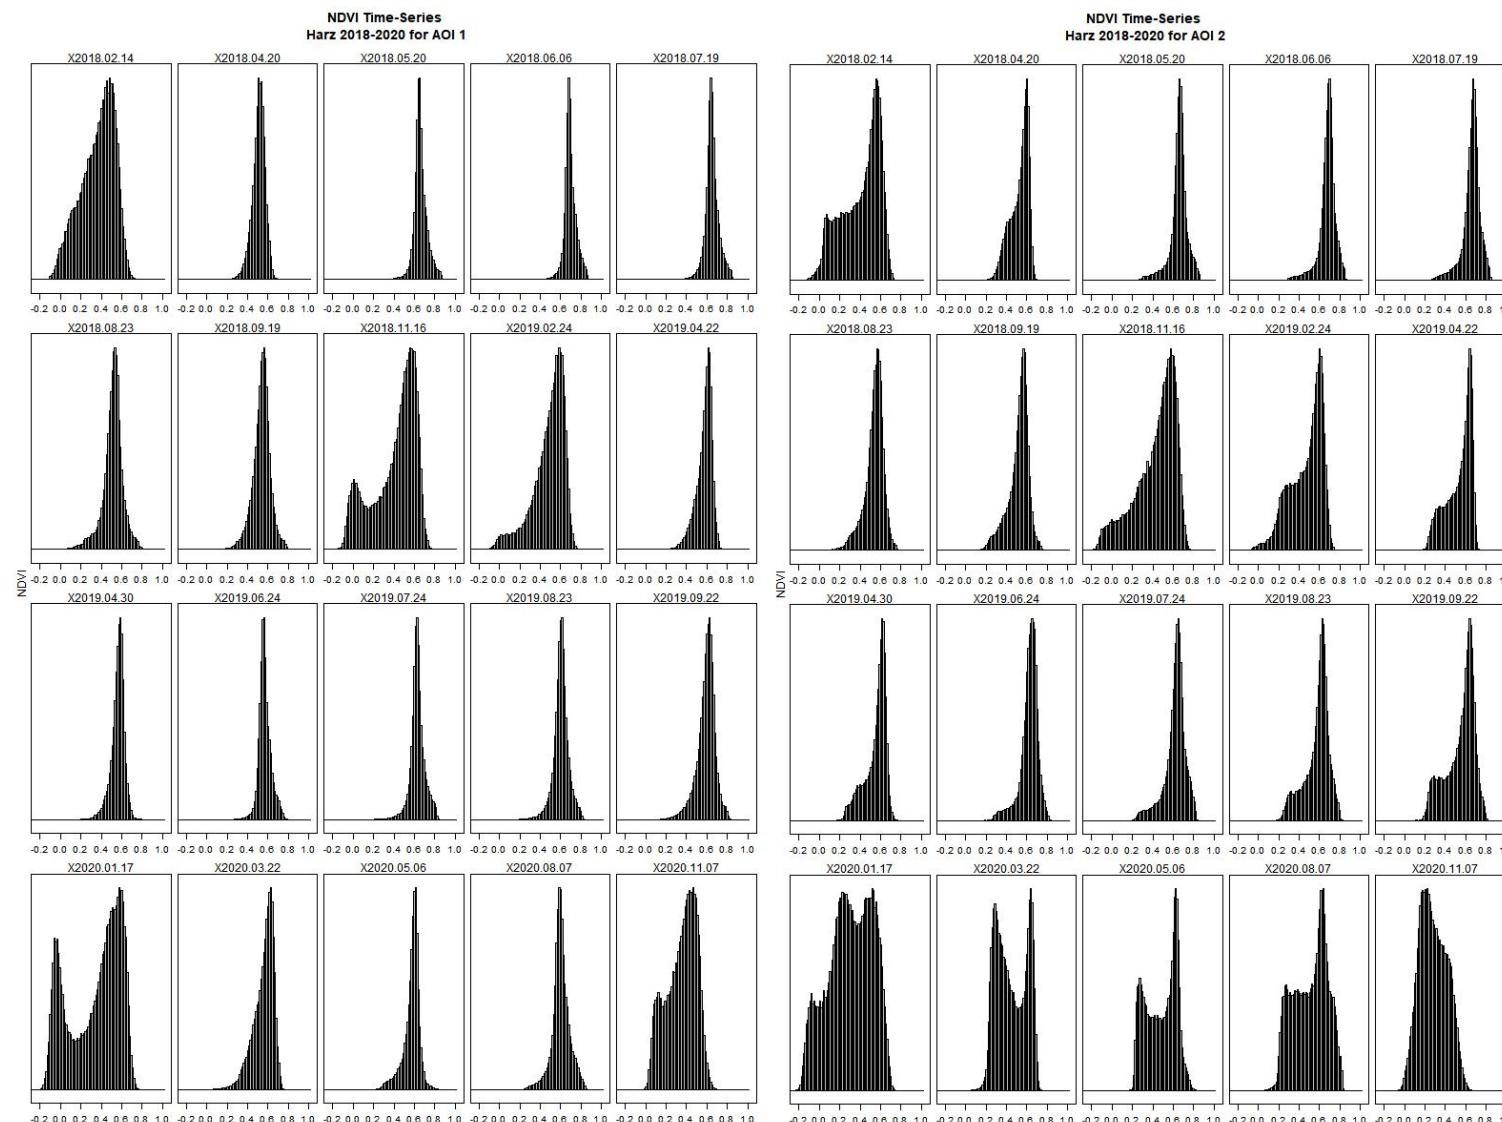
Anhang 1. Übersichtskarte über das Mittelgebirge Harz, Deutschland. Eingezeichnet sind die beiden Testflächen AOI 1 und AOI 2 [eigene Darstellung]

Anhang 2. Deskriptive Statistiken der beiden AOIs [eigene Darstellung]

Jahr	Monat	Minimum		Maximum		Mittelwert		Standardabweichung	
		AOI 1	AOI 2	AOI 1	AOI 2	AOI 1	AOI 2	AOI 1	AOI 2
2018	Februar	-0.143	-0.147	0.775	0.76	0.364	0.407	0.164	0.186
2018	April	0.163	0.137	0.695	0.745	0.509	0.527	0.062	0.089
2018	Mai	0.187	0.122	0.876	0.868	0.662	0.656	0.064	0.085
2018	Juni	0.226	0.157	0.877	0.86	0.696	0.678	0.058	0.082
2018	Juli	0.19	0.123	0.864	0.854	0.651	0.658	0.066	0.087
2018	August	-0.018	0.01	0.808	0.777	0.512	0.537	0.099	0.092
2018	September	0.11	0.07	0.801	0.773	0.537	0.519	0.084	0.099
2018	November	-0.349	-0.213	0.777	0.786	0.407	0.429	0.212	0.198
2019	Februar	-0.14	-0.127	0.771	0.778	0.484	0.471	0.156	0.158
2019	April	0.123	0.125	0.757	0.744	0.575	0.536	0.077	0.123
2019	April	0.161	0.147	0.795	0.762	0.561	0.55	0.064	0.103
2019	Juni	0.26	0.165	0.792	0.842	0.57	0.623	0.059	0.088
2019	Juli	0.163	0.132	0.843	0.843	0.633	0.62	0.07	0.103
2019	August	0.192	0.17	0.828	0.822	0.606	0.577	0.072	0.118
2019	September	0.124	0.029	0.835	0.817	0.594	0.551	0.087	0.137
2020	Januar	-0.201	-0.257	0.762	0.745	0.34	0.303	0.248	0.211
2020	März	0.034	0.032	0.765	0.753	0.558	0.446	0.098	0.146
2020	Mai	0.162	0.129	0.839	0.824	0.575	0.484	0.078	0.148
2020	August	0.168	0.052	0.858	0.838	0.602	0.512	0.085	0.164



Anhang 3. Plots der Zeitreihe der NDVI-Werte 2018-2020, links: AOI 1, rechts: AOI 2 [eigene Darstellung]



Anhang 4. Histogramme der Zeitreihe der NDVI-Werte 2018-2020, links: AOI 1, rechts: AOI 2 [eigene Darstellung]